

Regressão Linear Simples

1. INTRODUÇÃO

A regressão e a correlação são técnicas utilizadas para estimar uma relação que possa existir na população, enquanto as técnicas anteriormente estudadas (Medidas de Tendência Central e de Dispersão: Média, Desvio Padrão, Variância, etc.) servem para estimar um único parâmetro populacional.

A análise de correlação e regressão compreende a análise de dados amostrais para saber se e como duas ou mais variáveis estão relacionadas uma com a outra numa população.

A correlação mede a força, ou grau, de relacionamento entre duas variáveis; a regressão dá a equação que descreve o relacionamento em termos matemáticos.

Os dados para análise de regressão e correlação provêm de observações de variáveis emparelhadas. Na regressão pressupõe-se alguma relação de causa e efeito, de explanação do comportamento entre as variáveis. Ex. a idade e a altura de cada indivíduo; a alíquota de imposto e a arrecadação; preço e quantidade.

2. REGRESSÃO LINEAR

2.1. Introdução

A regressão linear simples constitui uma tentativa de estabelecer uma equação matemática linear (linha reta) que descreva o relacionamento entre duas variáveis.

Da mesma forma como usamos a média para resumir uma variável aleatória, a reta de regressão é usada para resumir a estimativa linear entre duas variáveis aleatórias (Lapponi, 1997, p.344).

Há diversas formas de utilização de equações de regressão:

Estimar valores de uma variável, com base em valores conhecidos da outra. Em situações em que as duas variáveis medem aproximadamente a mesma coisa, mas uma delas é relativamente dispendiosa, ou difícil de lidar, enquanto que a outra não.

Explicar valores de uma variável em termos da outra, ou seja, confirmar uma relação de causa e efeito entre duas variáveis.

Predizer valores futuros de uma variável. Ex. aplicar testes para avaliar o sucesso de um ingressante na escola ou no emprego.

2.2. A Equação Linear (a reta de regressão)

Principais características:

- 1) O coeficiente angular da reta é dado pela tangente da reta e se denomina “b”.

- 2) A cota da reta em determinado ponto é o coeficiente linear denominado “a”, que é o valor de Y quando X=0.

Fórmula: $\hat{Y} = a + bX$

Nesse modelo se verifica que: (Lapponi, p. 345)

- 1) Para um valor X_i podem existir um ou mais valores de Y_i amostrados.
- 2) Para esse mesmo valor X_i se terá apenas um valor projetado $\hat{Y}_i$.
- 3) Para cada valor de X_i existirá um desvio d_i (ou erro e_i) dos valores de $\hat{Y}_i$, conforme indicado nas figuras da apresentação.
- 4) Sempre teremos observações que não são pontos da reta.

2.3 Decisão por um tipo de relação

Nem todas as situações são bem aproximadas por uma equação linear.

Quando os dados não podem ser aproximados por um modelo linear, as alternativas são procurar um modelo não-linear conveniente, ou transformar os dados para a forma linear. Por exemplo, a conversão de uma ou de ambas escalas em logaritmos dá por vezes um modelo linear.

3. DETERMINAÇÃO DA EQUAÇÃO MATEMÁTICA

Na regressão, os valores y são preditos com base em valores dados ou conhecidos de x. A variável y é chamada variável dependente, e a variável x, variável independente.

Que critério devemos aplicar para obter os valores dos coeficientes a e b?

Existem 2 critérios (Lapponi, p.345):

- 1) Ajustar uma reta horizontal de valor igual à média dos valores de y, isto é, $\bar{Y}$, pois a média é uma reta de regressão com $b = 0$.
- 2) Ajustar uma reta que divida os pontos observados de forma que a soma dos desvios seja nula. No entanto, a simples soma dos desvios leva à compensação dos desvios positivos e negativos, como já se viu no cálculo da variância.

3.1. O método dos mínimos quadrados

O critério é encontrar os coeficientes a e b da reta de regressão que minimizem a soma dos quadrados dos desvios. (Lapponi, p. 346)

Características importantes:

- 1) A soma dos desvios verticais dos pontos em relação à reta é zero
- 2) A soma dos quadrados desses desvios é mínima (isto é, nenhuma outra reta daria menor soma de quadrados de tais desvios).

Simbolicamente, o valor que é minimizado é:

$$\sum d_i^2 = \sum (y_i - y_c)^2$$

Onde:

y_i = valor observado de y

y_c = o valor calculado de y utilizando-se a equação de mínimos quadrados com o valor de x correspondente a y_i .

Os coeficientes são calculados pelas fórmulas abaixo.

Tendo presente que $Cov(x,y) = r_{xy} \sigma_x \sigma_y$, o coeficiente b será igual a estas quatro fórmulas possíveis:

Fatos importantes da equação de regressão:

- 1) trata-se de uma média
- 2) seria muito arriscado extrapolar essa equação para fora do âmbito dos dados
- 3) a reta de regressão tem a interessante propriedade de passar sempre pelo ponto $(\bar{x}, \bar{y})$.

$$b = \frac{n(\sum xy) - (\sum x)(\sum y)}{n(\sum x^2) - (\sum x)^2} = \frac{Cov(x,y)}{Var(x)} = \frac{r_{xy}\sigma_x\sigma_y}{\sigma_x^2} = r_{xy} \frac{\sigma_y}{\sigma_x}$$

$$a = \frac{\sum y - b\sum x}{n} = \bar{y} - b\bar{x}$$

Quando existirem duas séries de dados, existirão várias medidas estatísticas que podem ser usadas para capturar como as duas séries se movem juntas através do tempo. As duas mais largamente usadas são a correlação e a covariância. Para duas séries de dados, X ($X_1, X_2, \dots$) and Y ($Y_1, Y_2, \dots$), a covariância fornece uma medida não padronizada do grau no qual elas se movem juntas, e é estimada tomando o produto dos desvios da média para cada variável em cada período.

O sinal na covariância indica o tipo de relação que as duas variáveis tem. Um sinal positivo indica que elas movem juntas e um negativo que elas movem em direções opostas. Enquanto a covariância cresce com o poder do relacionamento, ainda é relativamente difícil fazer julgamentos sobre o poder do relacionamento entre as duas variáveis observando a covariância, pois ela não é padronizada. A correlação é a medida padronizada da relação entre duas variáveis. Ela pode ser calculada da covariância.

$$Cov(X,Y) = \frac{1}{n} \sum_{j=1}^n (x_j - \mu_x)(y_j - \mu_y)$$

Uma vantagem adicional destas várias formas de cálculo é que com os mesmos dados é possível calcular as duas possíveis retas de regressão linear, permutando as variáveis de dependente (Y) para independente (X) e vice-versa, tendo presente que:

- 1) O valor do coeficiente b é obtido como resultado da divisão da covariância das duas variáveis aleatórias pela variância da variável independente.
- 2) O valor do coeficiente a é obtido como resultado da subtração da média da variável dependente menos o produto do coeficiente b pela média da variável independente.
- 3) Isto poderá indicar o sentido da relação causa-efeito ou explanatória.

Minimizar a soma dos quadrados dos desvios não garante que se tenha obtido a melhor reta ajustada, é apenas uma propriedade desejada de ajuste de reta. (Lapponi, p. 346)

O método de ajuste dos mínimos quadrados é preferível por que:

- 1) Obtém as melhores estimações, isto é, as estimativas não terão tendenciosidade.
- 2) Onera os desvios maiores, fato desejável que evita grandes desvios.
- 3) Permite realizar testes de significância na equação de regressão.
- 4) A reta de regressão passa pelo ponto formado pelos valores das médias das duas séries de observações.

3.2. Usando o Excel

As funções estatísticas que correspondem aos conceitos vistos até aqui são: INTERCEPÇÃO, INCLINAÇÃO, PREVISÃO e TENDÊNCIA.

1. INTERCEPÇÃO (série y; série x): dá como resultado o valor do coeficiente de regressão “a”, denominado intercepto da reta de regressão linear, ou seja, dá o valor de $\hat{Y}$ quando $X = 0$.
2. INCLINAÇÃO (série y; série x): dá como resultado o valor do coeficiente “b” da reta de regressão linear.
3. PREVISÃO (x; série y; série x): dá como resultado o valor projetado $\hat{Y}$ da reta de regressão linear simples para um único valor X. Deve-se ter o cuidado de escolher valores de X dentro da faixa de valores observados da variável independente.
4. TENDÊNCIA (série y; série x; x's; constante): dá como resultado o valor projetado $\hat{Y}$ da reta de regressão linear simples, para um único ou um grupo de valores de X, denominado como X's, quando conhecidas as duas séries de dados. Quando o argumento constante for:
 - a. VERDADEIRO (ou omitido) a função fornecerá um único ou um grupo de valores da reta de regressão $\hat{Y} = a + bx$.
 - b. FALSO, a função TENDÊNCIA fornece os resultados da reta de regressão $\hat{Y} = bx$, isto é, com $a = 0$.

A ferramenta mais completa é a Regressão (Análise de Dados) que será vista em mais detalhes em seguida, com a validação da regressão.

4. INFERÊNCIAS EM ANÁLISE DE REGRESSÃO

A reta de regressão calculada pode ser encarada como uma estimativa da relação real, porém desconhecida, que existe entre as duas variáveis na população.

Logo, os coeficientes a e b servem como estimativas pontuais dos dois parâmetros da população correspondente, A e B, e a equação $y_c = a + bx + u_c$ é a uma estimativa da relação populacional $y_i = A + Bx$.

Por que existe dispersão?

Porque não existe um relacionamento perfeito entre as duas variáveis na população. Há outras variáveis que influenciam os valores da variável dependente que não entram na análise de regressão.

Por que essas outras variáveis não estariam incluídas no estudo?

- a) Com influência provavelmente pequena de cada uma dessas variáveis, o custo da inclusão supera o benefício;
- b) Um ou dois fatores geralmente respondem por quase toda a variação da variável dependente;
- c) O número de variáveis explanatórias potenciais é muito grande, dificultando os cálculos.

Essa dispersão significa que há muitas equações de regressão diferentes, que poderiam concebivelmente ser obtidas. Para cada valor de x , haverá muitos valores possíveis de y .

Supõe que há uma distribuição de y 's potenciais que segue a lei normal, que é chamada distribuição condicional (isto é, dado x). A distribuição condicional é igual ao valor médio de y na população. Para esse particular x , $y = \alpha + \beta x$ é estimada por $y_c = a + bx$.

4.1. As premissas do modelo de regressão linear

1. Tem os parâmetros 'a' e 'b' lineares. Não pode ser b^2 , $\sqrt{a}$, etc.
2. Para cada valor de x existe um grupo de valores de y . Estes grupos de valores de y têm distribuição normal com o mesmo desvio padrão.
3. X , a variável independente, é não estocástica; é fixa em amostras repetidas; portanto se faz análise condicionada ao valor de X !
4. As médias das distribuições normais de y pertencem à reta de regressão.
5. O valor esperado dos desvios é nulo, pois a variância é mínima. $E(U_i | X_i) = 0$. Alguns valores de Y estão acima e outros abaixo da média (reta). Os resíduos são, portanto, positivos e negativos.
6. Homocedasticidade. Dado um valor de X , a variância dos desvios é constante e igual à variância da população; isto é, todos os desvios têm a mesma variância para todas as observações de X . $\text{Var}(U_i | X_i) = \sigma^2$; Na heterocedasticidade, $\text{Var}(U_i | X_i) = \sigma^2 i$.
7. Ausência de autocorrelação serial entre os resíduos. $\text{Cov}(U_i, U_j | X_i, X_j) = 0$. Os resíduos são independentes da variável independente. Se isto não existe, Y_t dependerá de X_t e de U_{t-1} .
8. $E(U_i, X_i) = 0$. Sem covariância entre U e X , pois U representa outras variáveis explicativas. Então se há esta correlação, outras variáveis estão influenciando X .
9. $n > k$; Ou seja, o número de observações tem que ser maior que o número de variáveis independentes.
10. $\text{Var}(X)$ deve ser positiva definida, isto é, X tem que variar na amostra.
11. Não pode haver erro ou viés na especificação do modelo.
12. Ausência de multicolinearidade. Para modelos múltiplos.
13. Os resíduos devem ter distribuição normal.

A partir de tais premissas, tem-se que responder à seguinte questão: Quão útil é a reta de regressão? A resposta estará baseada em duas medições importantes:

- a) O erro padrão da estimativa; e
- b) O coeficiente de determinação r^2 .

Estas estatísticas medem a eficiência dos estimadores, isto é a precisão com que a reta estará próxima dos valores observados de y . A menor variância é que definirá tal precisão.

4.2. Erro padrão da estimativa

Quão precisas são as diversas estimativas de regressão?

Devemos lembrar que os estimadores são função dos dados amostrais e variam, portanto, de amostra para amostra. Assim, genericamente, o erro padrão é o desvio padrão da distribuição dos estimadores em diversas amostragens.

A determinante principal da precisão é a quantidade de dispersão na população: quanto maior a dispersão, menor a precisão das estimativas.

A dispersão pode ser calculada pela fórmula, que é a raiz quadrada da variância:

$$S_e^2 = \frac{\sum_{i=1}^n (y_i - y_c)^2}{n - 2} = \frac{SSE}{n - 2}$$

$$S_e = \sqrt{\frac{\sum_{i=1}^n (y_i - y_c)^2}{n - 2}}$$

$$S^2 = \frac{S_{yy} - b S_{xy}}{N-2}$$

SSE=SQR → SQUARE SUM OF ERRORS; SOMA DOS QUADRADOS DOS RESÍDUOS

A razão para $(n - k) - [(n - 2)]$ é uma forma específica – é que perdemos k (número dos parâmetros estimados) graus de liberdade ao calcular as duas constantes 'a' e 'b' na equação de regressão. Portanto, k = graus de liberdade, isto é, restrições impostas ao total de observações. Lembre-se que uma reta necessita de pelo menos dois pontos; logo, para os pontos 'a' e 'b' são necessários duas das observações (quaisquer).

O uso de y_c em lugar de y decorre de querermos usar a reta de regressão como centro, ou ponto de referência, para medir a dispersão em relação à reta.

Se os dados observados estiverem, por exemplo, contidos numa reta, se obterá uma reta estimada coincidente com estes pontos observados e s_e , a soma dos quadrados dos desvios será igual a zero e a explicação da reta ajustada é completa.

Portanto, o valor de s_e é a parte não explicada pela regressão.

O cálculo do erro padrão se baseia na hipótese de dispersão uniforme, que supõe que as distribuições condicionais dos valores de y tenham desvios padrões iguais.

Este erro padrão é o desvio padrão da distribuição de pontos em torno da reta de regressão.


Com dois estimadores lineares e não-viesados, escolhe-se o de menor variância (em torno da média). Será o mais eficiente.

4.3. Coeficiente de Determinação, r^2

Uma medida útil, associada à reta de regressão, é o grau em que as predições baseadas na equação de regressão superam as predições baseadas no valor médio de y . O Coeficiente de Determinação pode ser definido como o grau de ajuste da reta estimada ao conjunto de dados. Quão bem o modelo se ajusta ao conjunto de dados.

Esta comparação pode ser analisada pela figura abaixo:

Poder de Explicação de r^2



onde:

- Variação Total: é a distância entre o valor médio de y e o valor observado de cada y ; o somatório do quadrado dos desvios das observações y com relação ao valor da média y das mesmas observações y , isto é, $\sum (y_i - y_{\text{médio}})^2$ é sua medida estatística.
- Variação não-explicada: é a distância entre os valores estimados pela reta e os valores observados de y ; o somatório do quadrado dos desvios das observações y com relação aos valores estimados pelo modelo de regressão, isto é, $\sum (y_i - y_c)^2$ é sua medida estatística.
- Variação explicada: é a distância entre o valor médio de y e os valores estimados pelo modelo para cada y ; o somatório do quadrado dos desvios dos valores estimados pelo modelo de regressão y_c com relação ao valor médio de y , isto é, $\sum (y_c - y_{\text{médio}})^2$ é sua medida estatística.
- Conclui-se, então que [Variação total = variação explicada + variação não-explicada].

A percentagem de variação explicada, r^2 , é a razão da variação explicada sobre a variação total.

Note a diferença entre os conceitos de variação e variância, já que variância = variação/gl.

A variação total também é conhecida pela expressão TSS=STQ (TOTAL SQUARE SUM =SOMA TOTAL DOS QUADRADOS). A variação não explicada é o que já vimos acima como erro padrão da estimativa (SSR=SQR). Resta a variação explicada, que é tratada como SQE=ESS (SOMA DOS QUADRADOS EXPLICADA=EXPLAINED SUM OF SQUARE).

$$r^2 = \frac{\text{variação explicada}}{\text{variação total}} = \frac{\sum (y_c - \bar{y})^2}{\sum (y_i - \bar{y})^2}$$

$$r^2 = \frac{\text{variação total} - \text{variação não explicada}}{\text{variação total}}$$

$$R^2 = \frac{bS_{xy}}{S_{yy}}$$

$$r^2 = 1 - \frac{\text{variação não explicada}}{\text{variação explicada}} = 1 - \frac{\sum (y_i - y_c)^2}{\sum (y_c - \bar{y})^2}$$

A medida r^2 reflete até que ponto os valores de y estão relacionados com os de x. Se $r^2 = 0$, então $b = 0$ e o valor médio de y é a melhor projeção para qualquer valor de x.

O coeficiente de determinação r^2 indica a proporção da variação total na variável dependente y que é explicada pela variação da variável independente x.

Se r^2 é próximo de 1, isso significa que a variação explicada responde por uma grande percentagem da variação total. Se $r^2 = 0,81$, por exemplo, indica que aproximadamente 81% da variação em y está relacionada com a variação de x e que 19% não é explicado por x.

O fato de r^2 não estar próximo de zero sugere que a equação é melhor que a média de y como preditor.

4.4. Usando o Excel

As funções estatísticas EPADYX e RQUAD.

EPADYX (série y; série x) dá como resultado o valor do erro padrão da estimativa s_e da reta de regressão linear.

RQUAD (série y; série x) dá como resultado o valor do coeficiente de determinação r^2 da reta de regressão linear.

5. ANÁLISE DOS ESTIMADORES

5.1 Inferências sobre o coeficiente angular da reta de regressão

Mesmo quando há pouco ou nenhum relacionamento entre variáveis numa população, é ainda possível obter valores amostrais que façam as variáveis parecerem relacionadas, pois fatores aleatórios na amostragem podem produzir um relacionamento aparente, decorrente apenas de flutuações da amostragem, onde nenhum existe.

Daí a importância de se testarem os resultados a fim de decidir se estes são estatisticamente significativos (isto é, se os verdadeiros parâmetros não são nulos). Para tanto, criam-se as hipóteses NULA e ALTERNATIVA abaixo:

$$H_0: B = 0$$

$$H_1: B \neq 0$$

O erro padrão do coeficiente b indica, por um lado, aproximadamente quão distante o coeficiente b está do coeficiente da população B, devido à variabilidade amostral.

Enquanto o teste de significância para b indicará se este coeficiente angular estimado é ou não diferente de zero, a hipótese, teórica ou empírica, nula assumida na análise.

A significância do coeficiente de regressão pode ser testada também, comparando-se a estatística t (distribuição de student) calculada a partir de seu erro padrão s_b , assim definido:

$$S_b = \frac{S_e}{\sqrt{S_{xx}}}$$

Fórmulas alternativas podem ser vistas em compêndios de estatística, por exemplo, Lapponi, (pg.358). As fontes prováveis de erro, ainda segundo Lapponi (pg. 359) são as seguintes:

- A reta da população é desconhecida, porém é estimada a partir das observações. Como as retas da média da população e da amostra são paralelas, existirá sempre uma diferença constante igual à diferença dos valores das médias de y .
- Aceitando $b \neq B$, as retas da população e da amostra têm apenas um valor coincidente e o erro da projeção aumenta, ou diminui, com a diferença de declividade.
- Existem erros de outras fontes, que se refletem em valores de observações que não representam fielmente a população.

De posse desta estatística de variação, pode-se calcular o Intervalo de Confiança $(1 - \alpha)$, onde se examinará a probabilidade de B estar contido no mesmo, assumindo determinado Nível de Significância (α) de cometer equívocos na decisão inferencial (no caso, Erro do Tipo I – rejeitar a hipótese nula, sendo ela verdadeira).

$$\Pr \{b - t.s_b \leq B \leq b + t.s_b\} = (1 - \alpha)$$

O intervalo de confiança atende a finalidade dupla:

- Indica o intervalo provável em que o verdadeiro valor B pode estar, dado um Nível de Significância (α);
- Será usado para testar a significância estatística do estimador angular amostral, admitindo-se, por hipótese, que o verdadeiro valor de B , desconhecido, é ZERO.
 - A resposta será dada pelo intervalo de confiança para B , que é $b \pm t.s_b$; se este contiver o valor hipotético de B , se aceita a hipótese nula.

Outra forma de realizar o teste da significância estatística do estimador b será calculando a estatística t referente à mostra e comparando a mesma com um valor crítico de t , estabelecido pelo

$$t = \frac{b}{S/\sqrt{S_{xx}}}$$

$$\text{pesquisador. } t = \frac{b - B}{S_b} = \frac{b}{S_b} = \frac{\text{valor amostral} - \text{valor esperado}}{\text{erro padrão do estimador}}$$

A simplificação ocorreu, dado que, por hipótese, o valor esperado do parâmetro é zero. É bom salientar que o uso da distribuição t ao invés da distribuição z deve-se ao fato de que se usa, no cálculo do erro padrão, valores amostrais; isto implica, entre outras coisas, usar graus de liberdade (gl), ao invés do número de observações (n).

Compara-se, então, t calculado com t crítico (a um dado nível de significância):

SE t CALCULADO < t CRÍTICO: ACEITA H_0 .

Pode-se também calcular a probabilidade (área dada pela função densidade de t) associada ao t calculado e compará-la a um dado Nível de Significância (α); esta medida é chamada de p-value ou sig. Se ela for maior que o Nível de Significância escolhido, se aceita a hipótese nula.

Vale comentar, finalizando, que, neste caso, aceitar a Hipótese Nula, significa concluir que $B = 0$; logo o modelo de regressão efetuado não é válido, pois se a inclinação do coeficiente angular é nula, a variável X nada explica sobre a variável dependente Y e a média desta última é um melhor estimador para os valores esperados na população.

5.2. Inferências sobre o coeficiente linear da reta de regressão

O erro padrão do coeficiente a pode ser mensurado através da seguinte fórmula:

$$S_a = S_e \sqrt{\frac{1}{n} + \frac{\bar{X}^2}{S_{xx}}}$$

Esta medida, assim como à mesma referente ao coeficiente angular, está expressa em termos da variável dependente Y e carece de inferências a partir de testes, pois está relacionada com a média de Y, valor esperado fundamental dos eventos relacionados a esta variável.

5.3. Inferências sobre reta de regressão como um todo (ANOVA)

A distribuição t é usada para realizar testes de hipóteses dos coeficientes da reta de regressão, enquanto que a distribuição F é usada para realizar testes de hipóteses da equação da reta de regressão como um todo.

Da mesma maneira que o Coeficiente de Determinação provê uma medida global de explicação das variações ocorridas na variável dependente Y decorrentes de variações na variável independente X, tais variações podem ser testadas em termos de significância estatística.

A ANOVA, usando a distribuição F (assim chamada por ter sido desenvolvida por Fischer), testa a hipótese de que nenhum dos coeficientes de regressão tenha significado.

O uso da distribuição F, ao invés das distribuições z ou t, está associado ao fato de que este teste envolve mais de uma variável independente e/ou mais de uma amostra, além de usar dados amostrais e não populacionais; deste modo os graus de liberdade se expressam tanto no numerador quanto no denominador da fórmula da estatística.

Em termos de análise de regressão:

$$F = \frac{\frac{\sum_{i=1}^n (y_i - \bar{y})^2}{K - 1}}{\frac{\sum_{i=1}^n (y_i - y_c)^2}{n - k}}$$

Onde:

n = número de observações da amostra
k = número de amostras/número de variáveis

$$F = \frac{\text{Variação Explicada}}{\text{Variação não Explicada}}$$

A significância da reta de regressão linear simples pode ser testada apenas usando-se as técnicas da análise de regressão vistas acima, dado que a distribuição F é igual ao quadrado da distribuição t, ou ainda, o teste F com 1 grau de liberdade no numerador é igual a um teste t; portanto, o uso desta

ferramenta ganha sentido com regressões múltiplas (mais de uma variável explicativa) e com experimentos com várias amostras.

Neste caso, seu uso será válido apenas supondo-se que as k amostras são independentes e que foram extraídas de populações normais com variâncias iguais.

5.4. Intervalos de Predição para Análise de Regressão

A previsão de y a partir de um valor de x resultará sempre em um valor médio e não mais o mesmo do par de observações original, pois a relação da reta é média entre x e y .

Para fazer tais previsões, não se devem utilizar valores que extrapolem aqueles utilizados na regressão, pois valores abaixo ou acima podem não manter a mesma relação observada na amostra. Portanto, a regressão é muito mais instrumento de inferência que de predição indiscriminada.

O valor predito de y , obtido da equação de regressão para um valor específico de x , pode ser encarado de duas maneiras:

- a) Considerando y_c como valor médio;
- b) Considerando y_c como valor individual.

Em ambos os casos o valor é o mesmo, mas o intervalo de confiança para tal predição depende do ponto de vista adotado, pois o erro padrão da média é diferente (menor) que o erro padrão para um valor individual qualquer (Ver as fórmulas em Corrar, pg. 109).

Isto porque os valores individuais são análogos a uma população de valores, enquanto que os valores médios são análogos a uma distribuição amostral de médias daquela população (pelo teorema do limite central, portanto, com desvio padrão menor que o desvio padrão da população).

Em resumo, usando um dado valor de x , o intervalo de confiança de y (y médio ou y individual) usando a fórmula genérica do erro padrão, será:

y médio: $y_c \pm ts_{y_c}$

y individual: $y_i \pm ts_{y_i}$

Se pudéssemos calcular intervalos de confiança para todos os valores possíveis de x , o resultado seria um par de faixas de confiança em torno da reta de regressão.

As faixas (e, portanto, os intervalos de confiança) são mais estreitas quando $x = x$ médio, e que eles vão se alargando à medida que aumenta a distância de x em relação à média.

5.5. Usando o Excel

A função estatística PROJ.LIN fornece todos os resultados numa única célula.

PROJ.LIN (série y ; série x ; constante; estatísticas) dá como resultado uma matriz com os resultados da reta de regressão linear múltipla $y_c = a + b_1x_1 + b_2x_2 + \dots + b_nx_n$ aplicando o método dos mínimos quadrados, onde os argumentos têm os seguintes significados:

- É conhecida a série de dados ou observações, série y .
- São conhecidas uma ou mais séries de dados ou observações, série x , tendo presente que:
- Quando existe apenas uma variável independente, a forma dos intervalos das duas variáveis y e x pode ter qualquer forma.

- Quando existe mais de uma variável independente, deve ser informado o intervalo abrangendo todas as variáveis independentes juntas.
- Quando a informação da variável independente é omitida, a função assume que x é uma matriz de números $\{1,2,3,\dots\}$ com o mesmo comprimento que a variável y .
- Definido o argumento constante como:
 - VERDADEIRO (ou omitido) a função fornece todos os coeficientes a e b 's da reta de regressão linear múltipla completa.
 - FALSO a função fornece apenas os coeficientes b 's da reta de regressão com $a=0$.
- Definindo o argumento estatística como:
 - ◆ FALSO a função fornece somente os coeficientes a e b 's.
 - ◆ VERDADEIRO (ou omitido) a função fornece os coeficientes a e b 's e as seguintes estatísticas: erros padrões dos coeficientes a e b 's; o coeficiente de determinação r^2 ; o erro padrão da estimativa S_e ; o valor da estatística F ; o número de graus de liberdade gl da regressão; a soma dos quadrados dos desvios explicados SSR ; a soma dos quadrados dos desvios não-explicados SSE .

PROJ.LOG (série y ; série x ; constante; estatísticas): dá como resultado uma matriz de resultados de uma curva exponencial de regressão do tipo $y_c = b \times m_1^{x_1} \times m_2^{x_2} \times \dots \times m_n^{x_n}$, aplicando o método dos quadrados mínimos, onde os argumentos têm os seguintes significados:

- É conhecida a série de dados ou observações, série y .
- São conhecidas uma ou mais séries de dados ou observações, série x , tendo presente que:
 - Quando existe apenas uma variável independente, a forma dos intervalos das duas variáveis y e x pode ter qualquer forma.
 - Quando existe mais de uma variável independente, deve ser informado o intervalo abrangendo todas as variáveis independentes juntas.
 - Quando a informação da variável independente é omitida, a função assume que x é um array de números $\{1, 2, 2, \dots\}$ com o mesmo comprimento que a variável y .
- Definido o argumento constante como:
 - VERDADEIRO (ou omitido) a função fornece todos os coeficientes b e m 's da curva exponencial de regressão.
 - FALSO a função fornece apenas os coeficientes m 's da reta de regressão $y_c = m_1^{s_1} \times m_2^{x_2} \times \dots \times m_n^{x_n}$, isto é, $b=1$.
- Definindo o argumento estatística como:
 - FALSO a função fornece somente os coeficientes b e m 's.
 - VERDADEIRO (ou omitido) a função fornece os coeficientes b e m 's e as seguintes estatísticas: erros padrões dos coeficientes b e m 's; o coeficiente de determinação r^2 ; o erro padrão da estimativa S_e ; o valor da estatística F ; o número de graus de liberdade gl da regressão; a soma dos quadrados dos desvios explicados SSR ; a soma dos quadrados dos desvios não-explicados SSE .

5.6. Ferramenta de análise regressão

Realiza a análise da regressão linear múltipla, incluindo o caso de regressão linear simples. As informações necessárias são as seguintes:

- Intervalo Y de entrada: informamos o intervalo da série de observações dependentes.
- Intervalo X de entrada: informamos o intervalo da série de observações independentes, num máximo de 16 observações.
 - Constante é zero: selecionamos esta opção quando queremos que a linha de regressão passe pela origem.
 - Rótulos: selecionamos este item, se os intervalos das séries incluírem os nomes das séries.
 - Nível de confiança: informamos o valor do nível de significância desejado.
- Opções de saída:
 - Na mesma planilha: escolhemos intervalo de saída e registramos o endereço,
 - Em outra planilha da mesma pasta: escolhemos nova planilha.
 - Em outra planilha de outra pasta: escolhemos nova pasta de trabalho.

Além dos resultados já estudados, essa ferramenta calcula, se aplicada a opção:

- Resíduos: para cada valor de x, é a diferença entre o valor observado e o valor projetado pela reta de regressão.
- Resíduos padronizados: para cada valor de x, é o resultado de dividir o valor do resíduo pelo erro da estimativa da regressão.
- Plotagem de resíduos: é o gráfico dos resíduos para cada valor de x.
- Plotagem de ajuste de linha: é o gráfico de dispersão xy contendo as observações e a reta de regressão.
- Plotagem de probabilidade normal: é o gráfico de cada observação y em função de seu correspondente percentil. O percentil de cada observação da série y ordenada de forma crescente é obtido com a expressão:

$$p = \frac{d-1}{n-1} \cdot 95\% + 5\%$$

- Nessa relação, n é o número total de observações da série, d é a ordem de uma determinada observação, e p é o percentil expresso em porcentagem dessa observação numa escala de 5% a 95%.

VER ROTEIRO PARA CALCULO DA REGRESSÃO LINEAR

Exercícios 01: Certa empresa produz sapatos distribuindo-os através de uma rede por todo o interior do estado. Realizou uma pesquisa para determinar qual a relação que havia entre o preço do produto e a distancia do mercado consumidor da cidade produtora. Preço pela distância, dados hipotéticos. Determine a equação de regressão e desenvolva a teoria das hipóteses.

Distância (km)=(X)	Preço=(Y)	X ²	XY	Y ²	Y equação
50	36	2500	1800	1296	
240	48	57600	11520	2304	
150	50	22500	7500	2500	
350	70	122500	24500	4900	
100	42	10000	4200	1764	
175	58	30625	10150	3364	
485	91	235225	44135	8281	
335	69	112225	23115	4761	
1885	464	593175	126920	29170	

Exercícios 02: Idem ao exercício anterior, considerando $t_{c=3,18}$.

	X	Y	X ²	XY	Y ²
	5	10	25	50	100
	10	15	100	150	225
	15	25	225	375	625
	20	40	400	800	1600
	25	60	625	1500	3600
SOMA	75	150	1375	2875	6150

Exercícios 03: Conforme dados abaixo, calcule:

	X	Y	X^2	XY	Y^2
	3	13	9	39	169
	4	21	16	84	441
	5	31	25	155	961
	6	43	36	258	1849
	7	57	49	399	3249
SOMA	25	165	135	935	6669

- Equação da reta
- Testar a existência de regressão, através de Student com $\alpha=5\%$, $t_{c=3,18}$
- Construir o intervalo de confiança para $\alpha=5\%$, $t_{c=3,18}$
- Construir o intervalo de confiança para $\beta=5\%$, $t_{c=3,18}$
- Fazer uma projeção para $X=9$

Exercícios 04: Dado o quadro de vendas e preços de uma determinada mercadoria, determine:

	Quantidade=Y	Preço=X	Y ²	X ²	X*Y
1	2	4	4	16	8
2	1	6	1	36	6
3	3	3	9	9	9
4	1	5	1	25	5
5	4	1	16	1	4
6	3	2	9	4	6
soma	14	21	40	91	38

- Equação da reta
- Testar a existência de regressão, através de Student com $\alpha=5\%$. $t_{c=2,78}$
- Construir o intervalo de confiança para $\alpha=5\%$
- Construir o intervalo de confiança para $\beta=5\%$
- Fazer uma projeção para $X=9$

Exercícios 05: Uma empresa apresentou a seguinte tabela que relaciona seus custos com a quantidade produzida:

Quant.	Custos	Y	X	X ²	XY
10	100	100	10	100	1000
11	115	115	11	121	1265
13	125	125	13	169	1625
15	140	140	15	225	2100
16	150	150	16	256	2400
18	160	160	18	324	2880
	SOMA	790	83	1195	11270

Na tabela de Student, com $N-2=6-2=4$, temos $t_c=2,78$

- Testar a existência de regressão de Y sobre X, com nível de confiança de 95%
- Testar a existência de regressão, através de Student com $\alpha=5\%$
- Testar a existência de regressão, através de Student com $\beta=5\%$
- Determinar o coeficiente de determinação e correlação
- Fazer a projeção da quantidade produzida quando obtemos um custo de R\$180,00

Exercício 06: Para estudar a poluição de um rio, um cientista mediu a concentração de um determinado composto orgânico (Y) e a precipitação pluviométrica na semana anterior (X):

X	Y
0,91	0,10
1,33	1,10
4,19	3,40
2,68	2,10
1,86	2,60
1,17	1,00

- Existe alguma relação entre o nível de poluição e a precipitação pluviométrica?

Informa-se que $r = 0,89$. Teste sua significância, ao nível de 5%. $t_c=2,77$

Exercício 07: Procurando quantificar os efeitos da escassez de sono sobre a capacidade de resolução

de problemas simples, um agente tomou ao acaso 10 sujeitos e os submeteu a experimentação. Deixou-os sem dormir por diferentes números de horas, após o que solicitou que os mesmos resolvessem os itens "contas de adicionar" de um teste. Obteve, assim, os seguintes dados:

No de erros - y	Horas sem dormir - X
8	8
6	8
6	12
10	12
8	16
14	16
14	20
12	20
16	24
12	24

a) Calcule o coeficiente de correlação linear de Pearson e teste a sua significância ao nível de 1%. $t_{c=3,36}$.

b) Determine a equação de regressão linear. Teste a existência da regressão, ao nível de 1 % ($t_{c=3,36}$) e 5% ($t_{c=2,31}$).